编译原理

第三章 词法分析

编译程序总框

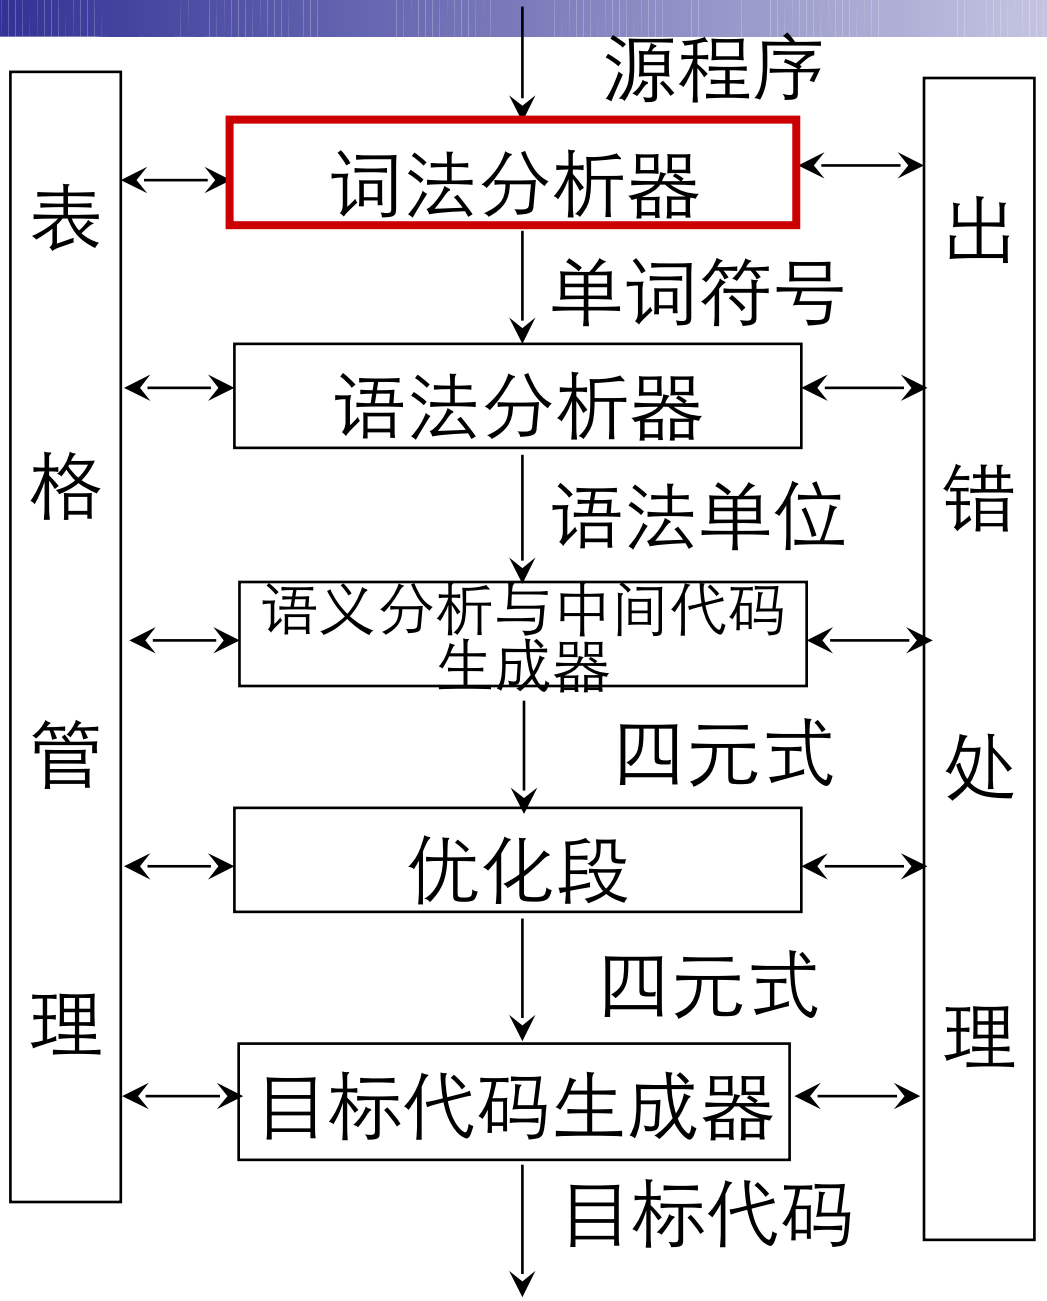
源程序
词法分析器
单词符号
语法分析器
语法单位
语义分析与中间代码生成器
四元式
优化段
四元式
目标代码生成器
目标代码
表格管理
出错处理

调查：词法分析程序

在操作系统的“shell 命令解释器”实验中，你是如何设计和实现命令的单词识别程序的（　）

A. 全部自己实现

B. 使用 LEX(FLEX) 工具实现

C. 使用其它词法分析程序开发工具实现

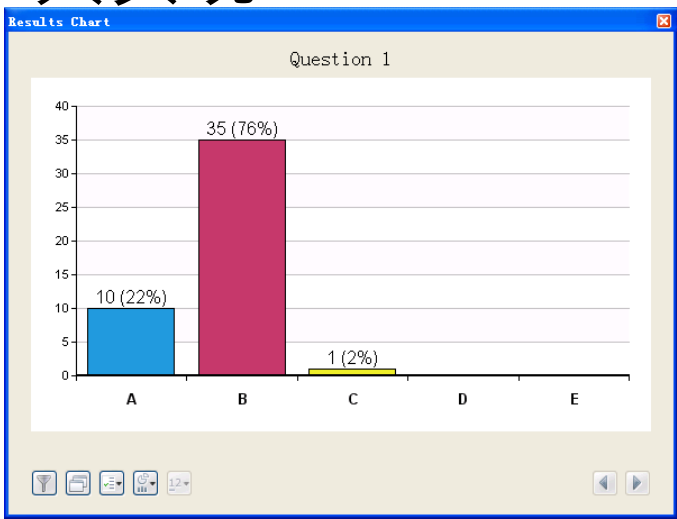

第三章 词法分析

- 对于词法分析器的要求
- 词法分析器的设计
- 正规表达式与有限自动机
- 词法分析器的自动产生 --LEX

第三章 词法分析

- 对于词法分析器的要求
- 词法分析器的设计
- 正规表达式与有限自动机
- 词法分析器的自动产生 --LEX

第三章 词法分析

- 词法分析的任务
  - 从左至右逐个字符地对源程序进行扫描，产生一个个单词符号
- 词法分析器 (Lexical Analyzer) 又称扫描器 (Scanner)
  - 执行词法分析的程序

3.1 对于词法分析器的要求

- 功能
  - 输入源程序、输出单词符号
- 单词符号的种类
  - 基本字：如 begin， repeat，…
  - 标识符——表示各种名字：如变量名、数组名和过程名
  - 常数：各种类型的常数
  - 运算符：+，-，*，/，…
  - 界符：逗号、分号、括号和空白

- 输出的单词符号的表示形式
  - (单词种别，单词自身的值)
- 单词种别通常用整数编码表示
  - 若一个种别只有一个单词符号，则种别编码就代表该单词符号。假定基本字、运算符和界符都是一符一种。
  - 若一个种别有多个单词符号，则对于每个单词符号，给出种别编码和自身的值。
    - 标识符单列一种；标识符自身的值表示成按机器字节划分的内部码
    - 常数按类型分种；常数的值则表示成标准的二进制形式

例　FORTRAN 程序

- IF (5.EQ.M) GOTO 100
- 输出单词符号
  - 逻辑 IF　　(34，-)
  - 左括号　　(2，-)
  - 整常数　　(20，‘5’的二进制)
  - 等号　　(6，-)
  - 标识符　　(26，‘M’)
  - 右括号　　(16，-)
  - GOTO　　(30，-)
  - 标号　　(19，‘100’的二进制)

例　C 程序

- while (i>=j) i--;
- 输出单词符号
  - < while，- >
  - < (，- >
  - < id，指向 i 的符号表项的指针 >
  - < >=，- >
  - < id，指向 j 的符号表项的指针 >
  - <)，- >
  - < id，指向 i 的符号表项的指针 >
  - < --，- >
  - < ;，- >

词法分析器作为一个独立子程序

- 词法分析是作为一个独立的阶段，是否应当将其处理为一遍呢?
  - 作为独立阶段的优点
    - 结构简洁、清晰和条理化，有利于集中考虑词法分析一些枝节问题
  - 不作为一遍
    - 将其处理为一个子程序

- 计算思维
  - 分解
  - 权衡

词法分析器在编译器中地位

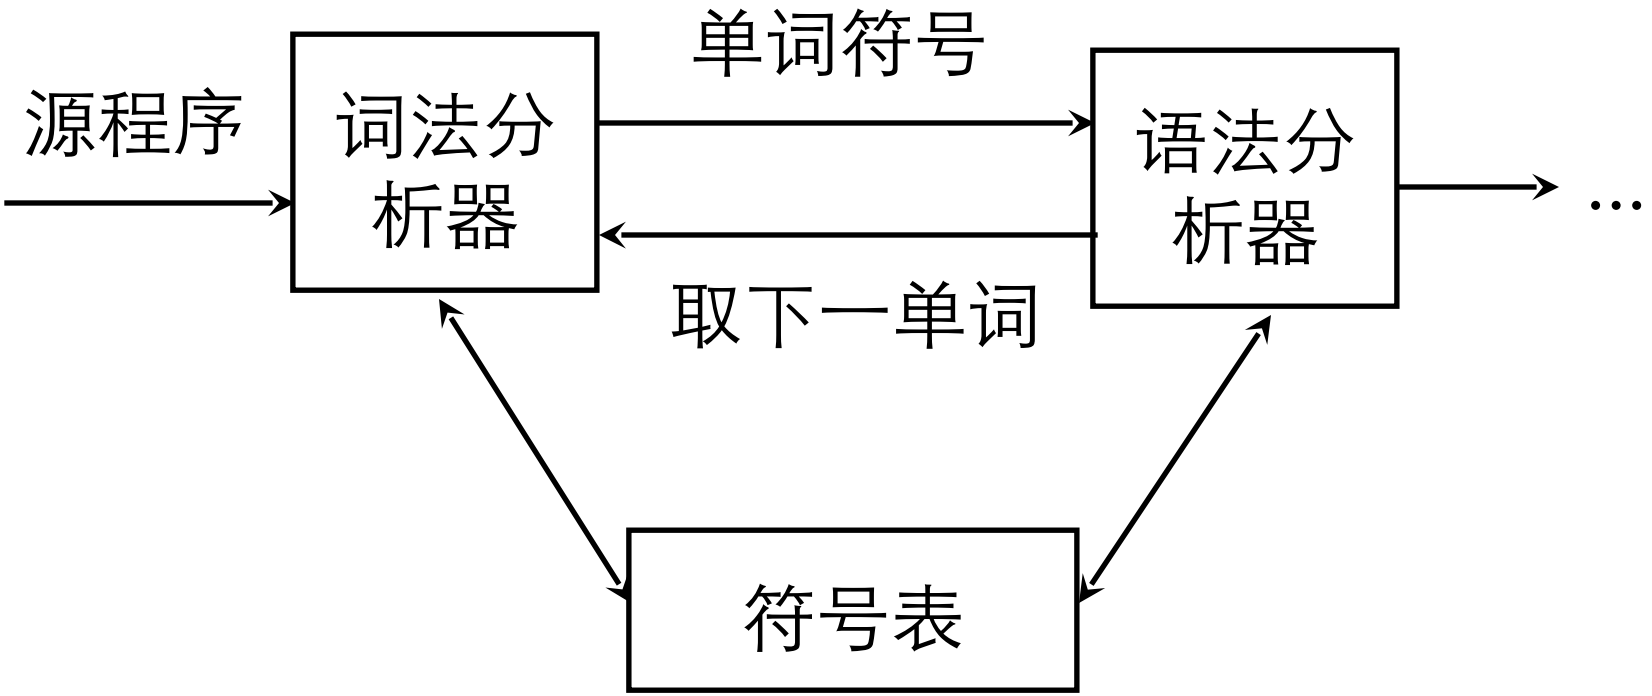

第三章 词法分析

- 对于词法分析器的要求
- 词法分析器的设计
- 正规表达式与有限自动机
- 词法分析器的自动产生 --LEX

- 计算思维
  - 分解

3.2 词法分析器的设计

- 词法分析器的结构

•剔除无用的空白、跳格、回车和换行等编辑性字符
•区分标号区、捻接续行和给出句末符等

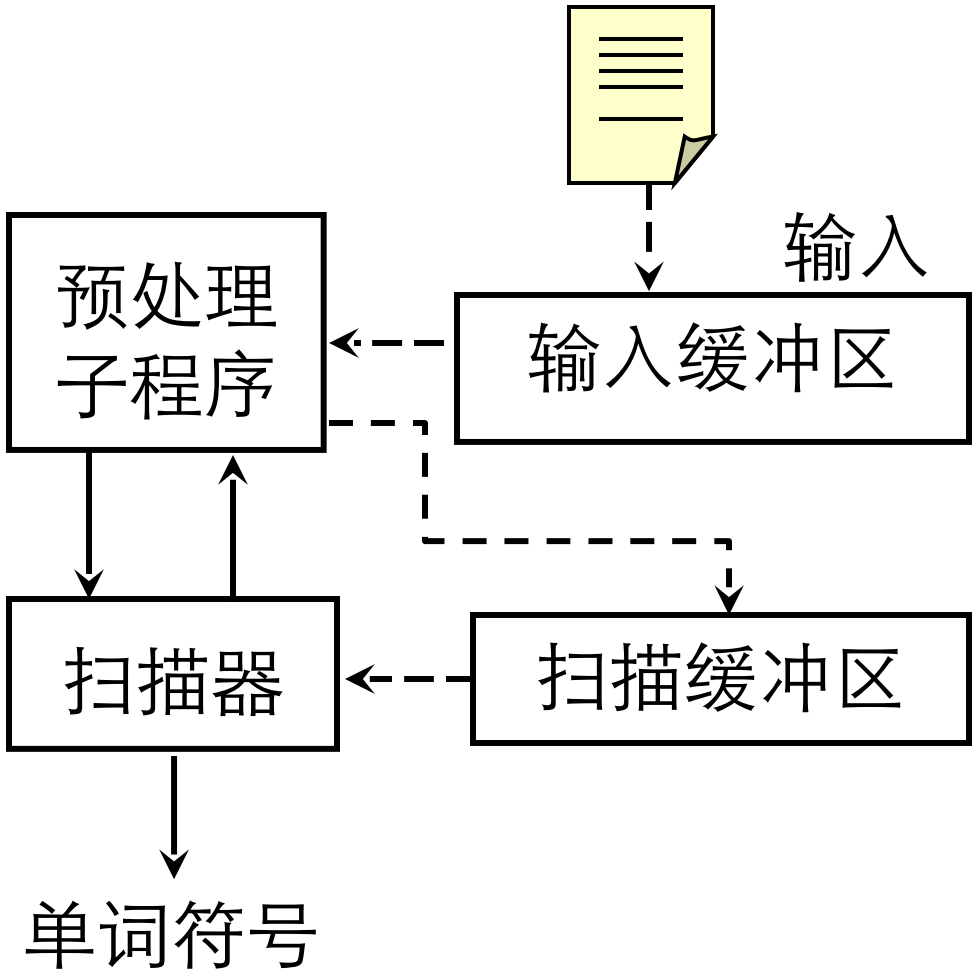

输入、预处理

- 扫描缓冲区

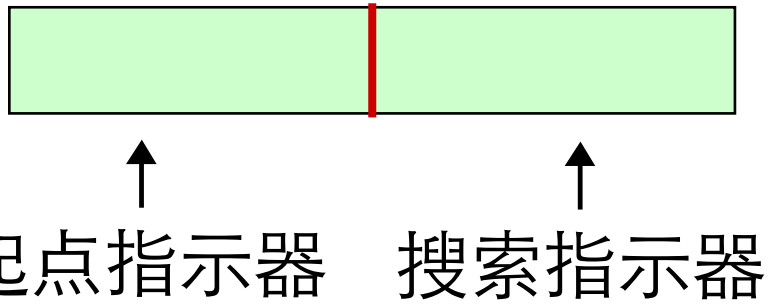

WhatALong…Word

rd.....	
… WhatALong…Wo	rd.....
rd.....	… WhatALong…Wo

两个半区互补使用
单词长度限制
= 半区的长度

单词符号的识别：超前搜索

- 基本字识别
- 例如

```
DO99K=1，10          DO 99 K = 1，10
DO99K=1.10
IF(5.EQ.M)GOTO55     IF (5.EQ.M) GOTO 55
IF(5)=55
```

- 需要超前搜索才能确定哪些是基本字

- 标识符识别
  - 字母开头的字母数字串，后跟界符或算符
- 常数识别
  - 识别出算术常数并将其转变为二进制内码表示。有些也要超前搜索。
    5.EQ.M
    5.E08
- 算符和界符的识别
  - 把多个字符符合而成的算符和界符拼合成一个单一单词符号。

    :=，　**，　.EQ.，　++，　--，　>=

几点限制——不必使用超前搜索

- 所有基本字都是保留字；用户不能用它们作自己的标识符
- 基本字作为特殊的标识符来处理，使用保留字表
- 如果基本字、标识符和常数（或标号）之间没有确定的运算符或界符作间隔，则必须使用一个空白符作间隔

  DO99K=1，10

  要写成　DO 99 K=1，10

调查：词法分析程序

在操作系统的“shell 命令解释器”实验中，你是如何设计和实现命令的单词识别程序的（　）

A. 全部自己实现

B. 使用 LEX(FLEX) 工具实现

C. 使用其它词法分析程序开发工具实现

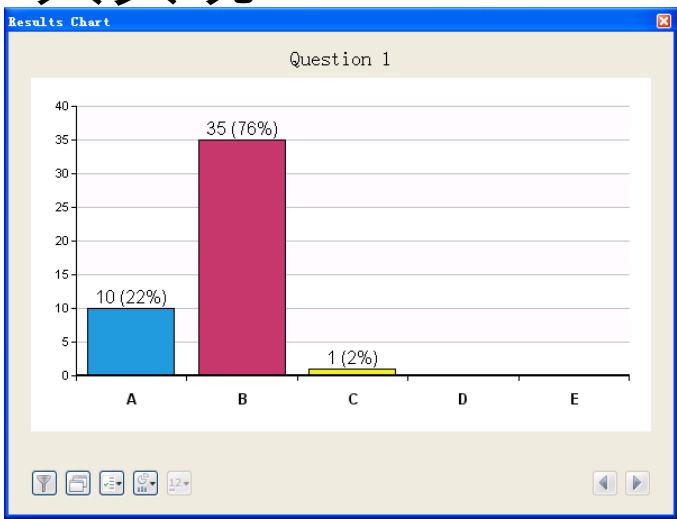

iclicker

状态转换图

- 状态转换图是一张有限方向图
  - 结点代表状态，用圆圈表示
  - 状态之间用箭弧连结，箭弧上的标记（字符）代表射出结状态下可能出现的输入字符或字符类
  - 一张转换图只包含有限个状态，其中有一个为初态，至少要有一个终态

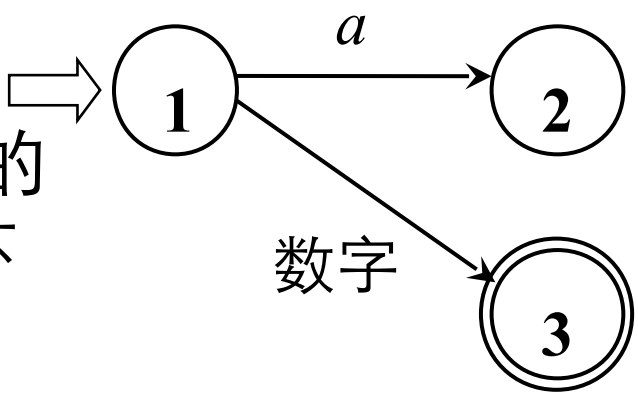

- 状态转换图可用于识别（或接受）一定的字符串
  - 若存在一条从初态到某一终态的道路，且这条路上所有弧上的标记符连接成的字等于α，则称α为该状态转换图所识别（接受）

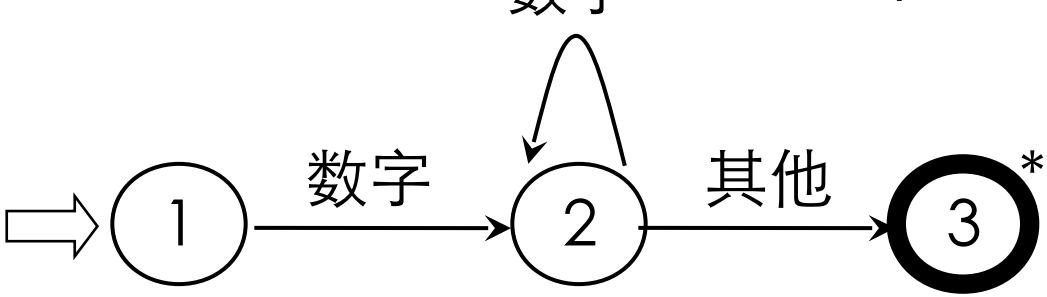

识别整常数的状态转换图

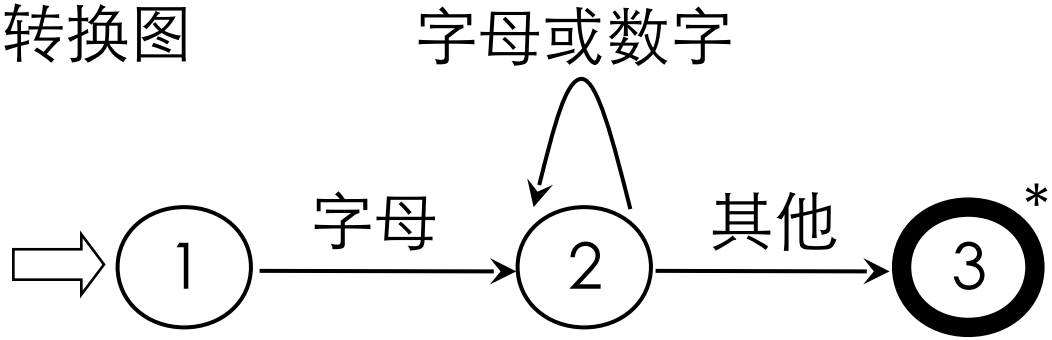

识别标识符的状态转换图

词法分析器的设计示例

- 助忆符
  - 直接用编码表示不便于记忆，因此用助忆符来表示编码。

单词符号	种别编码	助忆符	内码值
DIM	1	$DIM	-
IF	2	$IF	-
DO	3	$DO	-
STOP	4	$STOP	-
END	5	$END	-
标识符	6	$ID	内部字符串
常数（数）	7	$INT	标准二进制形式
=	8	$ASSIGN	-
+	9	$PLUS	-
*	10	$STAR	-
**	11	$POWER	-
,	12	$COMMA	-
(	13	$LPAR	-
)	14	$RPAR	-

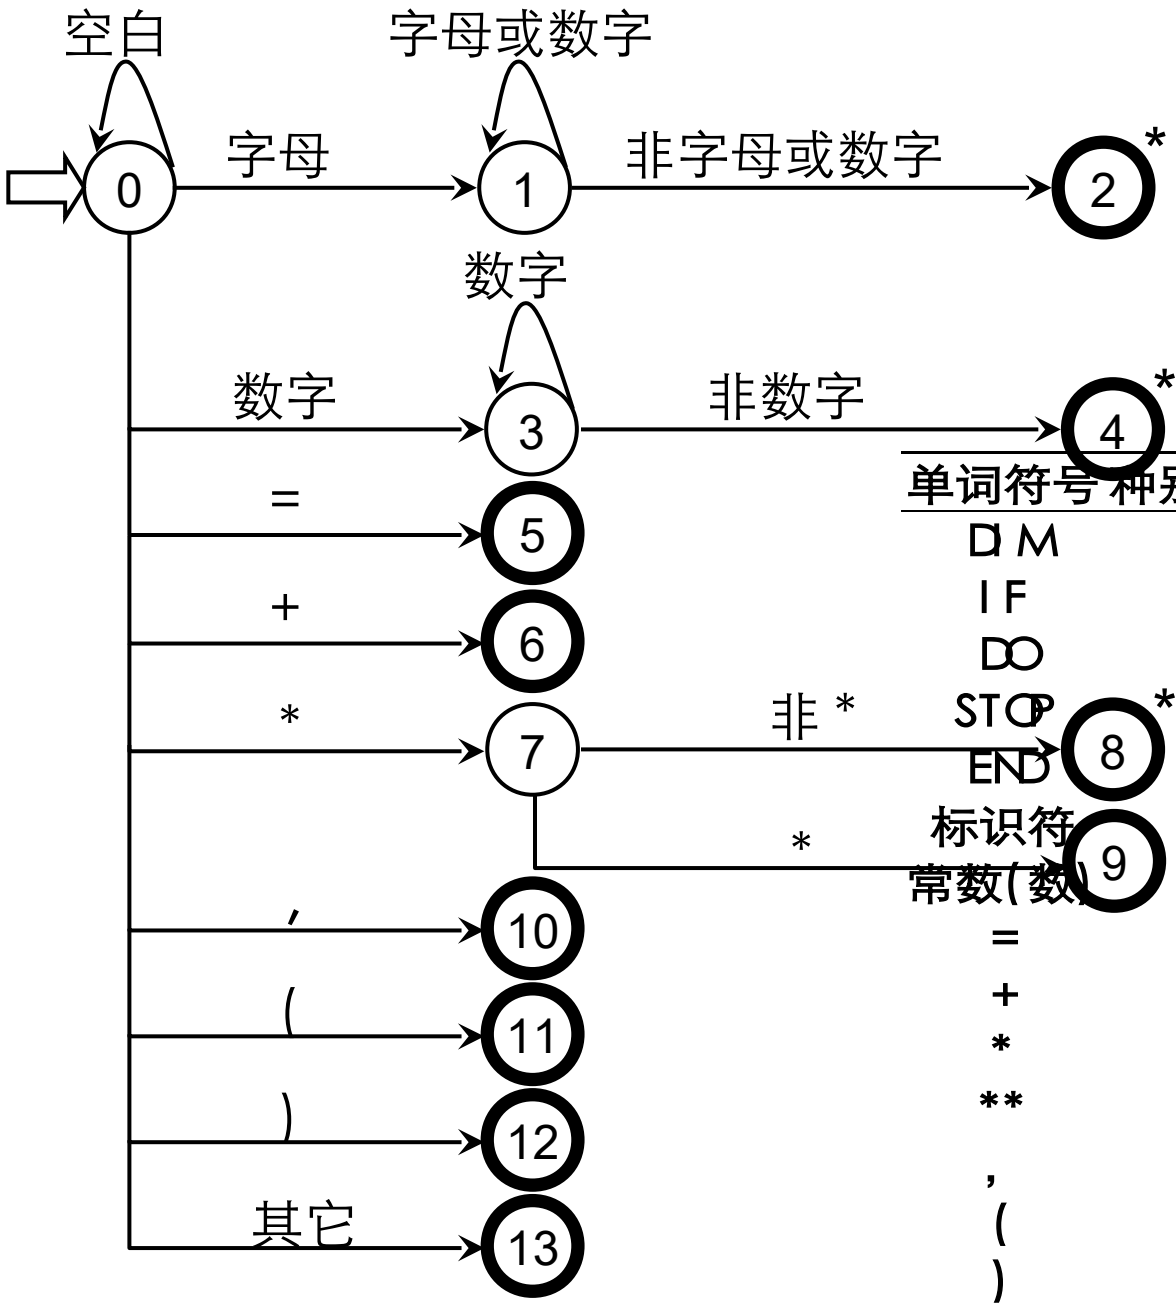

单词符号	种别编码	助忆符	内码值
DIM	1	$DIM	-
IF	2	$IF	-
DO	3	$DO	-
STOP	4	$STOP	-
END	5	$END	-
标识符	6	$ID	内部字符串
常数(数)	7	$INT	标准二进制形式
=	8	$ASSIGN	-
+	9	$PLUS	-
*	10	$STAR	-
**	11	$POWER	-
,	12	$COMMA	-
(	13	$LPAR	-
)	14	$RPAR	-

几点限制——不必使用超前搜索

- 所有基本字都是保留字；用户不能用它们作自己的标识符
- 基本字作为特殊的标识符来处理，使用保留字表
- 如果基本字、标识符和常数（或标号）之间没有确定的运算符或界符作间隔，则必须使用一个空白符作间隔

  DO99K=1，10

  要写成　DO 99 K=1，10

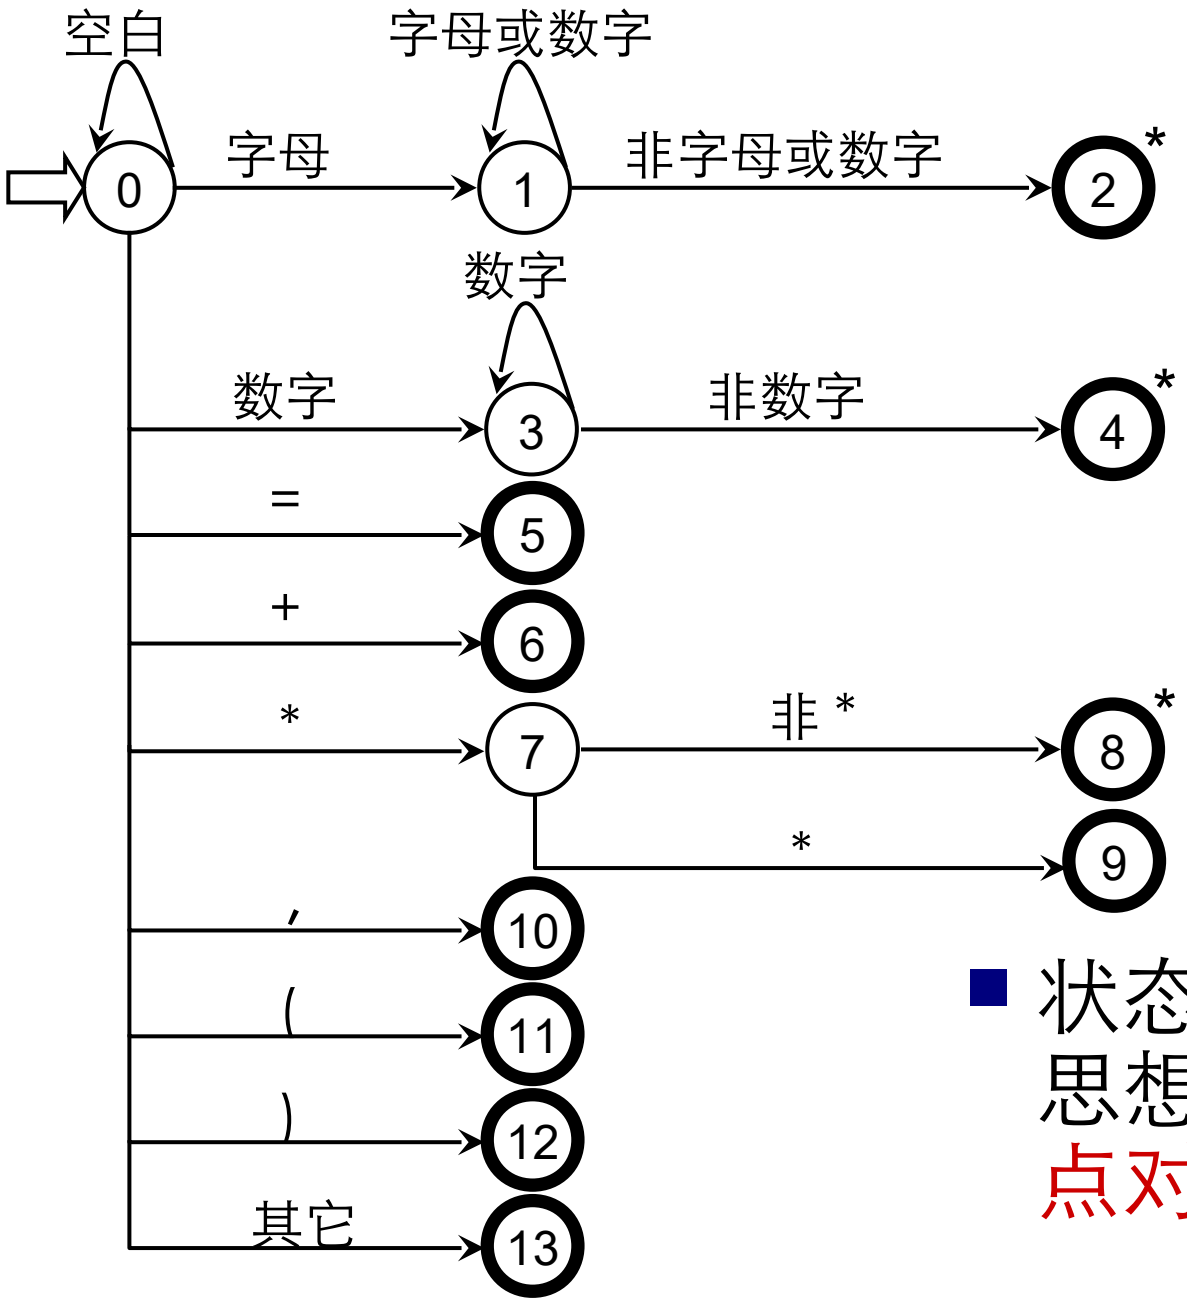

- 状态转换图的实现思想：每个状态结点对应一小段程序

状态转换图的实现

- 思想：每个状态结点对应一小段程序
- 具体方法

  1) 对不含回路的分叉结点，可用一个 CASE 语句或一组 IF-THEN-ELSE 语句实现

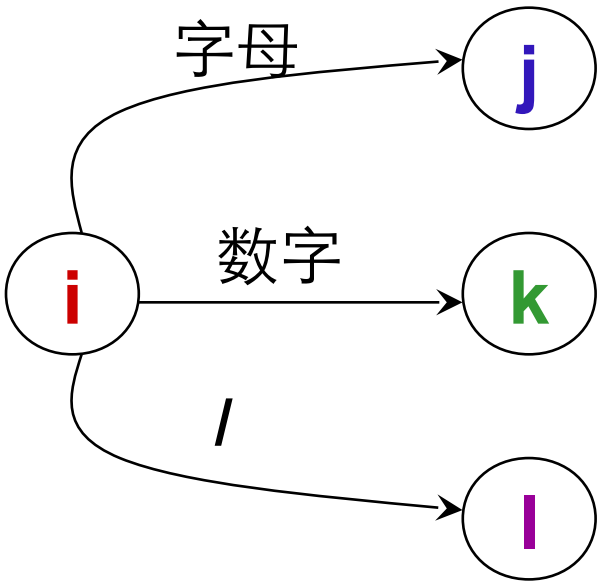


```
GetChar( );
if (IsLetter( ))
    {… 状态 j 的对应程序段… ;}
else if (IsDigit( ))
    {… 状态 k 的对应程序段… ;}
else if (ch='/')
    {… 状态 l 的对应程序段… ;}
else
    {… 错误处理… ;}
```

状态转换图的实现

- 具体方法

  2) 对含回路的状态结点，可对应一段由 WHILE 结构和 IF 语句构成的程序 .

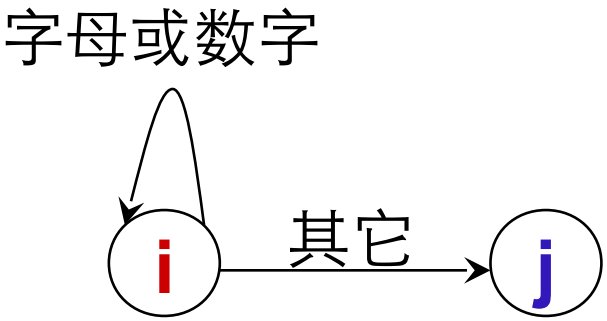


```
GetChar( );
while (IsLetter( )or IsDigit( ))
    GetChar( );
… 状态 j 的对应程序段…
```

状态转换图的实现

- 具体方法

  3) 终态结点表示识别出某种单词符号，因此，对应语句为

  RETURN (C , VAL)

  其中， C 为单词种别， VAL 为单词自身值

- 全局变量与过程

1) ch 字符变量、存放最新读入的源程序字符

2) strToken 字符数组，存放构成单词符号的字符串

3) GetChar 子程序过程，把下一个字符读入到 ch 中

4) GetBC 子程序过程，跳过空白符，直至 ch 中读入一非空白符

5) Concat 子程序，把 ch 中的字符连接到 strToken

6)IsLetter 和 IsDisgital 布尔函数，判断 ch 中字符是否为字母和数字

7) Reserve 整型函数，对于 strToken 中的字符串查找保留字表，若它实保留字则给出它的编码，否则回送 0

8) Retract 子程序，把搜索指针回调一个字符位置

9)InsertId 整型函数，将 strToken 中的标识符插入符号表，返回符号表指针

10)InsertConst 整型函数过程，将 strToken 中的常数插入常数表，返回常数表指针。

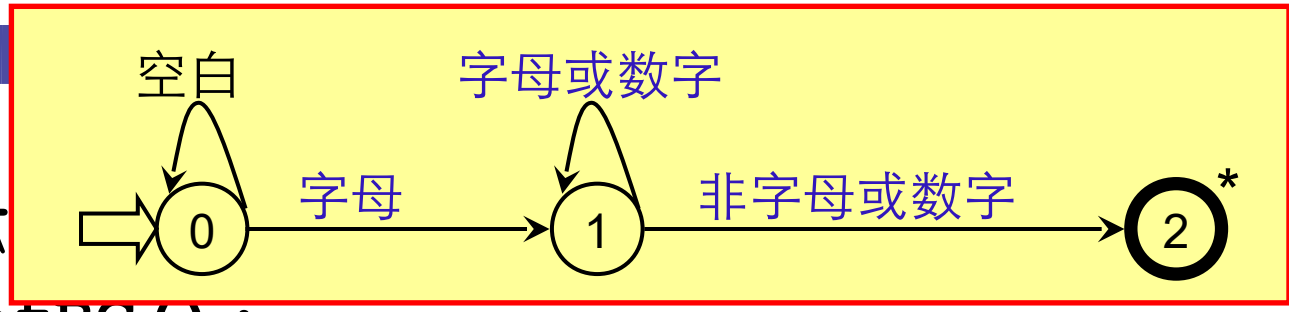


```
int code, val
strToken := "
GetChar(); GetBC();
if (IsLetter())
begin
     while (IsLetter() or IsDigit())
     begin
          Concat(); GetChar();
     end
     Retract();
     code := Reserve();
     if (code = 0)
     begin
          value := InsertId(strToken);
          return ($ID, value);
     end
     else
          return (code, -);
end
```

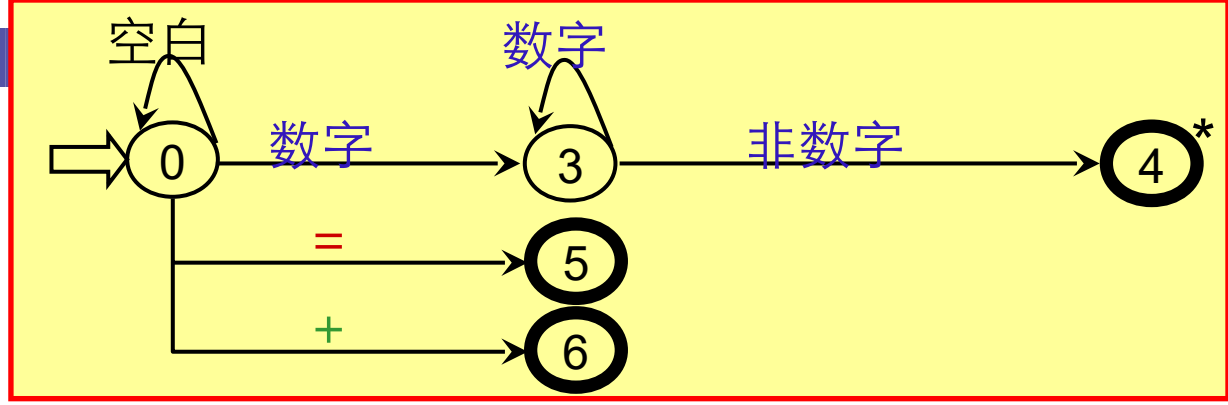


```
else if (IsDigit())
begin
     while (IsDigit())
     begin
          Concat( ); GetChar( );
     end
     Retract();
     value := InsertConst(strToken);
     return($INT, value);
end
else if (ch ='=') return ($ASSIGN, -);
else if (ch ='+') return ($PLUS, -);
```

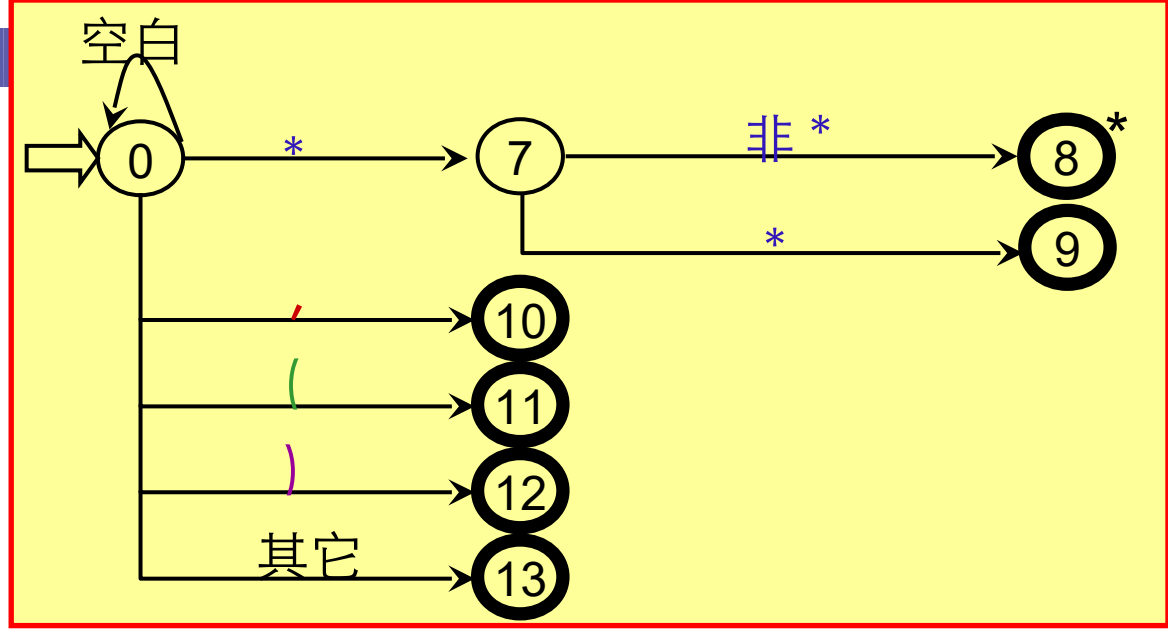


```
else if (ch ='*')
begin
      GetChar();
      if (ch ='*') return ($POWER, -);
      Retract(); return ($STAR, -);
end
else if (ch =',') return ($COMMA, -);
else if (ch ='(') return ($LPAR, -);
else if (ch =')') return ($RPAR, -);
else ProcError( );          /*  错误处理 */
```

将状态图的

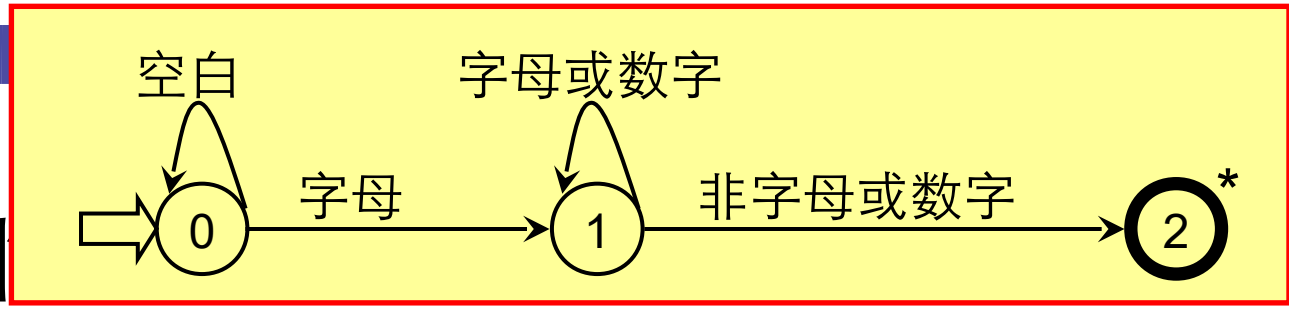

- 变量 curState 用于保存现有的状态
- 用二维数组表示状态图： stateTrans[state][char]

```
curState = 初态
GetChar();
while( stateTrans[curState][c
    // 存在后继状态，读入、拼接
    Concat();
    // 转换入下一状态，读入下一字符
   curState= stateTrans[curState][ch];
    if cur_state 是终态 then 返回 strToken 中的单词
    GetChar( );
}
```

只是个框架，还有很多细节需要考虑！
是否有自动的方法产生词法分析程序？

小结

- 词法分析器的功能
- 词法分析器的设计
  - 状态转换图
  - 状态转换图的实现

作业

- 阅读： PL 语言编译器的词法分析子程序 getsym
- 思考：如果语言扩展需要增加关键字或新数据类型的常量，需要如何修改程序?