编译原理

第三章 词法分析



- ■对于词法分析器的要求
- ■词法分析器的设计
- ■正规表达式与有限自动机
- ■词法分析器的自动产生 --LEX



- ■对于词法分析器的要求
- ■词法分析器的设计
- ■正规表达式与有限自动机
- ■词法分析器的自动产生 --LEX



DIM,IF, DO,STOP,END number, name, age 125, 2169






关系图

DIM,IF, DO,STOP,END number, name, age 125, 2169

正规集 3.3.1 DIM IF DO 正规式 **STOP END** letter(letter|digit)* digit(digit)*



1

确定有限自动机 (DFA)

■ 对状态图进行形式化,则可以下定义:

确定有限自动机 (DFA)M 是一个五元式 $M=(S, \Sigma, f, S_0, F)$, 其中:

- 1.S: 有穷状态集
- 2. Σ: 输入字母表(有穷)
- 3. f: 状态转换函数,为 $S \times \Sigma \rightarrow S$ 的<u>单值部分映射</u>, f(s, a)=s'表示: 当现行状态为 s, 输入字符为 a 时,将状态转换到下一状态 s'、s'称为 s 的一个后继状态
- $4. S_0 ∈ S$ 是唯一的一个初态
- 5 F⊂S: 终态集(可空)



■例如: DFA M=({0, 1, 2, 3}, {a, b}, f, 0, {3}), 其中: f定义如下:


	a	b
0	1	2
1	3	2
2	1	3
3	3	3

f(0		b))=2
٠,		7	\sim	_

$$f(1, b)=2$$

$$f(2, b)=3$$

$$f(3, b)=3$$



状态转换矩阵

状态转换图

关系图

DIM,IF, DO,STOP,END number, name, age 125, 2169,

letter(letter|digit)*

digit(digit)*

```
curState = 初态
GetChar();
while( stateTrans[curState][ch] 有定义){
    // 存在后继状态,读入、拼接
    Concat();
    // 转换入下一状态,读入下一字符
    curState= stateTrans[curState][ch];
    if cur_state 是终态 then 返回 strToken 中的单
    GetChar();
}
```

正规集
3.3.1
DIM
IF
DO
STOP
END

FA DFA

3.3.2
3.3.3

3.3.3 非确定有限自动机 (NFA)

■ 1976 年图灵奖


☐ For their joint paper "Finite Automata and Their Decision Problem," which introduced the idea of nondeterministic machines, which has proved to be an enormously valuable concept. Their (Scott & Rabin) classic paper has been a continuous source of inspiration for subsequent work in this field.

M. O. Rabin D. Scott†

Finite Automata and Their Decision Problems;

Abstract: Finite automate are considered in this paper as instruments for classifying finite tapes. Each one tomaton defines a set of tapes, a two-tape automaton defines a set of pairs of tapes, et cetera. The structure of the defined sets is studied. Various generalizations of the notion of an automaton are introduced

Michael O. Rabin





Dana S. Scott



3.3.3 非确定有限自动机 (NFA)

- 定义: 一个非确定有限自动机 (NFA) M 是一个五元式 M=(S, Σ , f, S₀, F) ,其中:
 - 1 S: 有穷状态集
 - 2 Σ : 输入字母表(有穷)
 - 3 f: **状态转换函数**,为 **S×Σ*→2**^s 的部分映射
 - 4 S₀⊆S 是非空的初态集
 - 5 F ⊂ S : 终态集(可空)







- 从状态图看 NFA 和 DFA 的区别
 - □可以有多个初态
 - □ 弧上的标记可以是∑*中的一个字(甚至可以是一个正规式),而不一定是单个字符
 - □同一个字可能出现在同状态射出的多条弧上
- DFA 是 NFA 的特例

对于Σ*中的任何字α,若存在一条从初态到某一终态的道路,且这条路上所有弧上的标记字连接成的字等于α(忽略那些标记为ε的弧),则称α为 NFA M 所识别(接收)


■ NFA M 所识别的字的全



NFA 示例



识别所有含相继两个 a 或相继两个 b 的字



re.

NFA 与 DFA

- 定义: 对于任何两个有限自动机 M 和 M', , 如果 L(M)=L(M'), 则称 M 与 M' 等价
- 自动机理论中一个重要的结论: 判定两个 自动机等价性的算法是存在的
- 对于每个 NFA M 存在一个 DFA M',使 得 L(M)=L(M')
- DFA 与 NFA 描述能力相同!


关系图

DIM, IF, DO, STOP, END number, name, age 125, 2169

```
curState = 初态
  GetChar();
  while( stateTrans[curState][ch] 有定义){
     // 存在后继状态,读入、拼接
     Concat();
     //转换入下一状态,读入下一字符
    curState= stateTrans[curState][ch];
     if cur state 是终态 then 返回 strToken 中的单
     GetChar();
                     FA
  正规集
                     DFA
                3.3.2
3,3,1
                3.3.3
```



正规式




M

证明:

- 1. 假定 NFA M=<S, Σ , δ , S₀, F> ,我们对 M 的状态转换图进行以下改造:
 - 引进新的初态结点 X 和终态结点 Y , X,Y ∉ S ,

从X到 S_0 中任意状态结点连一条 ϵ 箭弧,从F中任意状态结点连一条 ϵ 箭弧到Y。




10

证明:

- 1. 假定 NFA M=<S, Σ , δ , S₀, F> ,我们对 M 的状态转换图进行以下改造:
 - 引进新的初态结点 X 和终态结点 Y , X,Y ∉ S ,

从X到 S_0 中任意状态结点连一条 ϵ 箭弧,从F中任意状态结点连一条 ϵ 箭弧到Y。





证明:


- 1. 假定 NFA M=<S, Σ , δ , S₀, F> ,我们对 M 的状态转换图进行以下改造:
 - 引进新的初态结点 X 和终态结点 Y , X,Y ∉ S ,

从X到 S_0 中任意状态结点连一条 ϵ 箭弧,从F中任意状态结点连一条 ϵ 箭弧到Y。


2) 对 M 的状态转换图进一步施行替换,其中 k 是新引入的状态。

按下面的三条规则对箭弧进行分裂:






■识别所有含相继两个a或相继两个b的字



逐步把这个图转变为每条弧只标记为Σ上的一个字符或ε,最后得到一个 NFA M',
 显然 L(M')=L(M)



1


2. 把上述 NFA 确定化——采用子集法


- 设 | 是的状态集的一个子集,定义 | 的ε 闭包ε closure(I) 为:
 - i) 若 s∈l,则 s∈ε-closure(l);
 - ii) 若 $s \in I$,则从 s 出发经过任意条 ϵ 弧而能到达的任何状态 s '都属于 ϵ -closure(I)

即

ε-closure(I)=I∪{s' | 从某个 s∈I 出发经过任意条ε弧 能到达 s'} ■ 设 a 是Σ中的一个字符,定义 I_{α} = ε-closure(J)

其中,J为I中的某个状态出发经过一条 a 弧而到达的状态集合。





■ 设 a 是Σ中的一个 字符,定义 I_a= ε-closure(J)

其中, J为I中的 某个状态出发经 过一条 a 弧而到 达的状态集合。


确定化的过程

■ 不失一般性,设字母表只包含两个 a 和 b,我们构造一张表: ■ 黄生 異常 1 行策

ε-Closure({X})	{}	{}
{ }	{}	{}
{ }	{}	{}

- 首先,置第1行第1列为 ε-closure({X}) 求出这一 列的 Ι_α, Ι_β;
- 「■ 然后,检查这两个 l_a, l_b ,看它们是否已在表中的 第一列中出现,把未曾出 现的填入后面的空行的第 1 列上,求出每行第 2 , 3 列上的集合 …
 - 重复上述过程,直到所有 第2,3列子集全部出现 在第一列为止





I	$\mathbf{I_a}$	I_{b}
$\{X,5,1\}$	{5,3,1}	{5,4,1}
{5,3,1} {5,4,1}	{5,2,3,1,6,Y} {5,3,1}	{5,4,1} {5,2,4,1,6,Y}
$\{5,2,3,1,6,Y\}$	$\{5,2,3,1,6,Y\}$	$\{5,4,6,1,Y\}$
{5,2,4,1,6,Y} {5,4,6,1,Y}	{5,3,6,1,Y} {5,3,6,1,Y}	{5,2,4,1,6,Y} {5,2,4,1,6,Y}
{5,3,6,1,Y}	{5,2,3,1,6,Y}	{5,4,6,1,Y}

- 把这张表看成一个状态转换矩阵,把其中的每个 子集看成一个状态
- 这张表唯一刻划了一个确定的有限自动机 M
 - □初态是ε-closure({X})
 - □终态是含有原终态Y的子集
- 不难看出,这个 DFA M 与 M'等价

Ι	$\mathbf{I}_{\mathbf{a}}$	I_b
{X,5,1}	{5,3,1}	{5,4,1}
{5,3,1}	{5,2,3,1,6,Y}	{5,4,1}
{5,4,1}	{5,3,1}	{5,2,4,1,6,Y}
{5,2,3,1,6,Y}	{5,2,3,1,6,Y}	{5,4,6,1,Y}
{5,2,4,1,6,Y}	{5,3,6,1,Y}	{5,2,4,1,6,Y}
{5,4,6,1,Y}	{5,3,6,1,Y}	{5,2,4,1,6,Y}
{5,3,6,1,Y}	{5,2,3,1,6,Y}	{5,4,6,1,Y}

Ι	a	b	$a \bigwedge$
0	1	2	
1	3	2	$a \xrightarrow{1} \xrightarrow{a} \xrightarrow{3} \xrightarrow{5} \xrightarrow{5}$
2	1	4	$ \begin{array}{cccccccccccccccccccccccccccccccccccc$
3	3	5	$\begin{pmatrix} 0 \\ a \\ \end{pmatrix}$
4	6	4	$b \rightarrow (2) \rightarrow (4) \rightarrow (6)$
5	6	4	b A a
6	3	5	V b

小结

DIM

IF.

DO

STOP END

digit(digit)*

DIM, IF, DO, STOP, END number, name, age 125, 2169

```
curState = 初态
GetChar();
while( stateTrans[curState][ch] 有定义){
  // 存在后继状态,读入、拼接
  Concat();
  //转换入下一状态,读入下一字符
  curState= stateTrans[curState][ch];
  if cur state 是终态 then 返回 strToken 中的单
  GetChar();
```

